

Exercício - MT2 Data

2025-09-19

Sumário Executivo

Principais Achados

A análise do mercado da soja, com base nos dados de 2012 a 2024, demonstra que o preço doméstico da soja é fortemente influenciado pelo preço internacional da commodity e pela taxa de câmbio. As evidências empíricas indicam que choques negativos no preço internacional tendem a reduzir o preço doméstico. Além disso, variáveis como fertilizantes, produção doméstica e eventos climáticos (El Niño) também apresentaram certa relevância no comportamento da série.

Modelo Recomendado

O modelo recomendado é um ARIMA com variáveis exógenas (ARIMAX), ajustado sobre a série mensal de preços domésticos da soja. Esse modelo se apresentou bem especificado, tendo em vista resíduos ruído branco e ausência de autocorrelação dos resíduos. O uso de regressores externos — câmbio, preço global da soja, valor das exportações, custos de fertilizantes e choques climáticos — aumenta a capacidade explicativa em relação a modelos univariados, permitindo capturar a influência de fatores internacionais e domésticos sobre a formação de preços internos.

Implicações Econômicas para a Empresa

Os resultados evidenciam a alta sensibilidade do mercado interno às oscilações internacionais, sobretudo do preço global da soja e do câmbio. Para a empresa, isso implica que:

Gestão de risco cambial é essencial, uma vez que variações no câmbio amplificam os impactos externos sobre o preço doméstico.

Monitoramento do mercado internacional deve ser contínuo, dado o papel central do preço global da soja na formação dos preços internos.

Planejamento de produção e comercialização deve considerar cenários de queda internacional, já que a redução da rentabilidade pode afetar margens e exigir ajustes na estratégia de hedge.

Eventos climáticos e custos de insumos (fertilizantes) permanecem como fatores críticos para a previsibilidade e devem ser integrados a análises prospectivas.

Em síntese, a empresa deve adotar estratégias de hedge cambial e de preço alinhadas ao modelo ARIMAX, que permite antecipar movimentos de mercado e reduzir exposição a choques externos, fortalecendo a tomada de decisão em um ambiente de elevada volatilidade.

Dados

- Para a elaboração do modelo, utilizou-se como variável dependente o indicador de preço da soja Cepea/Esalq – Paranaguá à vista (R\$/60kg) (disponível em: <https://www.cepea.org.br/br/indicador/soja.aspx>). Como os dados possuem periodicidade diária, os valores foram agregados em médias mensais.

- Ademais, como variáveis explicativas, utilizaram-se os dados disponibilizados pelo exercício, aos quais foram adicionados: (i) o valor das exportações brasileiras de soja, mensurado em US\$ FOB milhões (disponível em: https://balanca.economia.gov.br/balanca/publicacoes_dados_consolidados/pg.html), e (ii) o preço global da soja, medido em USD/t (disponível em: <https://fred.stlouisfed.org/series/PSOYBUSDM>). Para a primeira variável, seu valor foi convertido para reais multiplicando-se pelo câmbio; para a segunda, aplicou-se a multiplicação pelo câmbio e pelo fator 0,06 (1 tonelada = 1000 kg), de modo a adequá-la à unidade de R\$/60 kg da variável dependente.

```
# 1) Pacotes -----

library('tidyverse')
library('janitor')
library('readxl')
library("tseries")
library("forecast")
library('knitr')
library("patchwork")
library("strucchange")


# 2) Dados -----

# Alterar esse endereço para reprodução do relatório
caminho_dados <- "C:/Users/lucac/OneDrive/Documentos/MT2_Data_exercicio/inputs/data.xlsx"

# 2.1) Preço da soja -----

soybean_price <- read_excel(caminho_dados, sheet = "soybean_price") %>%
  clean_names() %>%
  mutate(date = if (is.numeric(date)) {
    as.Date(date, origin = "1899-12-30")
  } else {
    as.Date(date, tryFormats = c("%Y-%m-%d", "%d/%m/%Y", "%m/%d/%Y"))
  }) %>%
  mutate(year = year(date), month = month(date)) %>%
  group_by(year, month) %>%
  summarise(soybean_price = mean(soybean_price, na.rm = TRUE),
    .groups = "drop") %>%
  mutate(date = as.Date(sprintf("%04d-%02d-01", year, month))) %>%
  dplyr::select(-year, -month)

# 2.2) Valor das exportações de soja -----

soybean_exp_value <- read_excel(
  caminho_dados,
  sheet = 'exp_value'
) %>%
  clean_names() %>%
  mutate(date = as.Date(paste0("01/", date), format = "%d/%m/%Y")) %>%
  arrange(date)
```

2.3) Valor das exportações de soja -----

```
soybean_global_price <- read_excel(  
  caminho_dados,  
  sheet = 'soybean_global_price'  
) %>% clean_names()
```

2.3) Dados do exercício -----

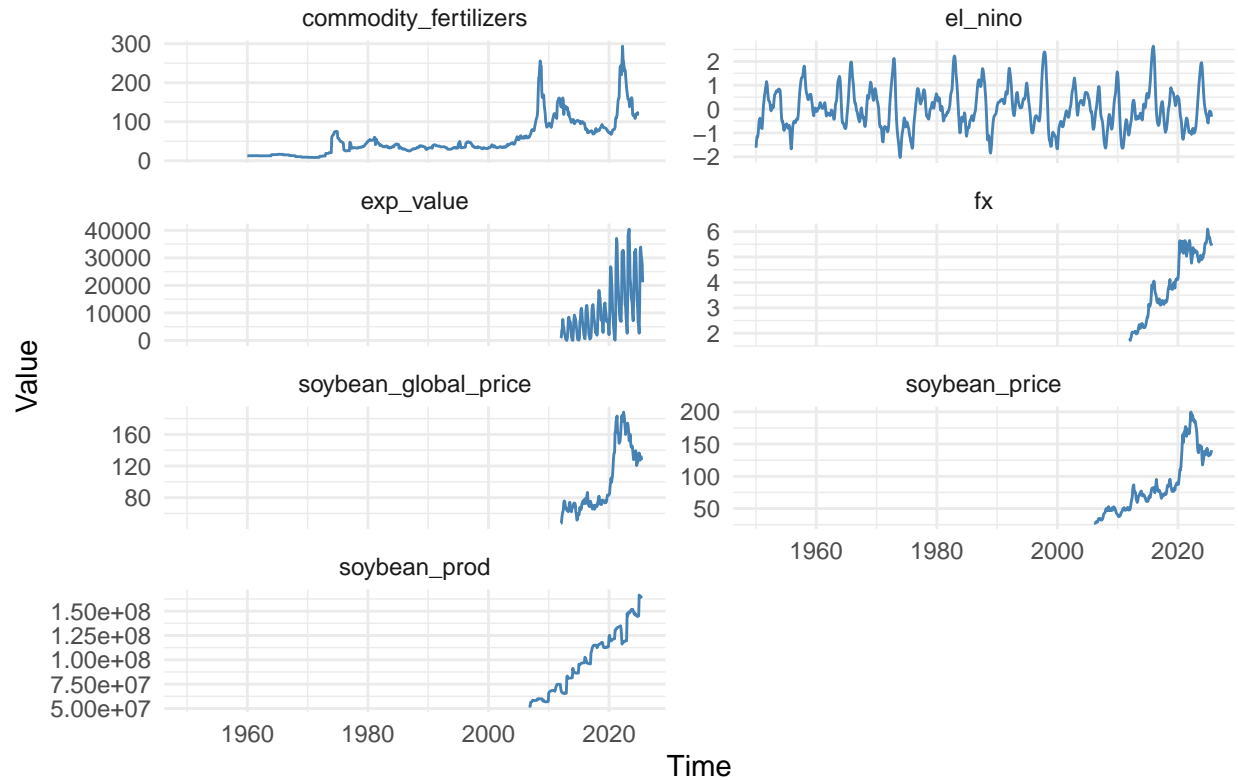
```
data_raw <- read_excel(caminho_dados) %>%  
  clean_names() %>%  
  rename(  
    fx = bcb_external_sec_exchange_rate_dolar_month_avg,  
    commodity_fertilizers = wb_commodity_fertilizers,  
    el_nino = noaa_oni,  
    soybean_prod = ibge_lsps_soybean_production  
  )
```

2.4) Dataset -----

```
dataset <- data_raw %>%  
  left_join(soybean_exp_value, by = "date") %>%  
  left_join(soybean_global_price, by = "date") %>%  
  left_join(soybean_price, by = "date") %>%  
  mutate(soybean_global_price = soybean_global_price * fx * 0.06,  
    exp_value = exp_value*fx) %>%  
  pivot_longer(  
    cols = -c(date),  
    names_to = "series",  
    values_to = "value"  
  )
```

```
ggplot(dataset, aes(x = date, y = value)) +  
  geom_line(color = "steelblue") +  
  facet_wrap( ~ series, scales = "free_y", ncol = 2) +  
  theme_minimal() +  
  labs(title = "Time Series", x = "Time", y = "Value")
```

Time Series



variavel	descricao
fx	Taxa de câmbio
commodity_fertilizers	Preço de fertilizante
soybean_prod	Produção doméstica de soja
el_nino	El Niño
exp_value	Valor das exportações de soja
soybean_global_price	Preço internacional da soja
soybean_price	Preço doméstico da soja

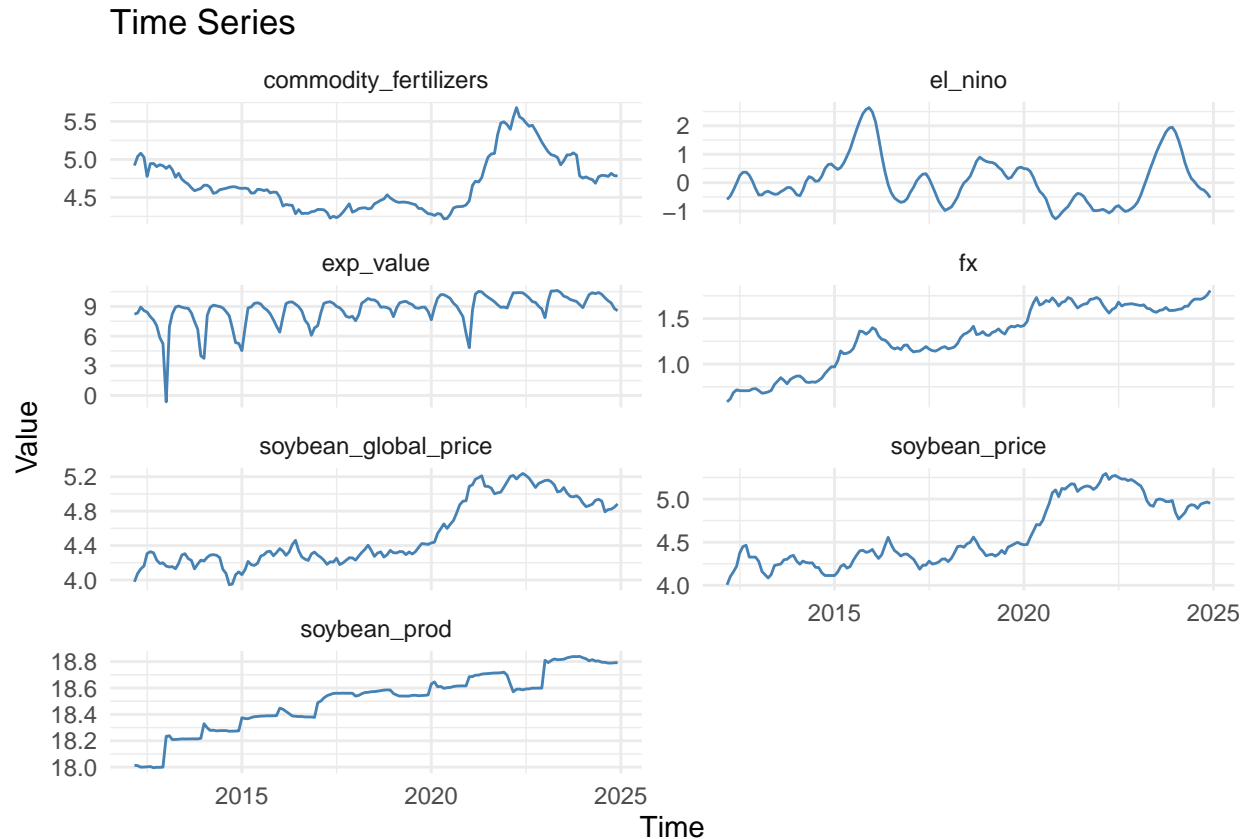
Exploração e Pré-processamento

- Tendo em vista as diferentes escalas das variáveis, o primeiro passo consiste em aplicar a transformação logarítmica, de modo a suavizá-las e facilitar a comparação. Tal processo não foi aplicado para variável de El Niño.
- Em segundo lugar, considerou-se o período de 2012-02-01 até 2024-12-01 para o exercício

```
dataset_final <- dataset %>%
  mutate(value = if_else(series != "el_nino", log(value), value),
         value = ts(value)) %>%
  filter(date >= "2012-02-01" & date <= "2024-12-01")

ggplot(dataset_final, aes(x = date, y = value)) +
  geom_line(color = "steelblue") +
  facet_wrap(~ series, scales = "free_y", ncol = 2) +
```

```
theme_minimal() +
labs(title = "Time Series", x = "Time", y = "Value")
```



Estacionariedade

No universo das séries temporais, o princípio da estacionariedade é fundamental para assegurar a robustez do processo estocástico gerador dos dados. Nesse sentido, utilizou-se o teste ADF para verificar se tal propriedade é atendida.

```
series <- unique(dataset_final$series)

adf_test_list <- list()

for (i in series) {

  adf_data <- dataset_final %>%
    filter(series == i) %>%
    pull(value) %>%
    na.omit()

  if(length(adf_data) > 0){
    adf_test_list[[i]] <- adf.test(adf_data)
  } else {
    adf_test_list[[i]] <- NA
  }
}
```

```

}

adf_summary <- data.frame(
  series = names(adf_test_list),
  test_stat = sapply(adf_test_list, function(x) if(is.list(x)) x$statistic else NA),
  p_value = sapply(adf_test_list, function(x) if(is.list(x)) x$p.value else NA),
  stationary = sapply(adf_test_list, function(x) if(is.list(x)) x$p.value < 0.05 else NA)
)

adf_summary %>%
  mutate(series = gsub("\\.Dickey-Fuller$", "", as.character(series))) %>%
  kable(row.names = FALSE, caption = "Resultado Teste ADF - 1ª Rodada")

```

Table 2: Resultado Teste ADF - 1ª Rodada

series	test_stat	p_value	stationary
fx	-2.405595	0.4073203	FALSE
commodity_fertilizers	-2.598922	0.3267421	FALSE
soybean_prod	-3.661281	0.0299999	TRUE
el_nino	-2.833774	0.2288566	FALSE
exp_value	-8.238062	0.0100000	TRUE
soybean_global_price	-1.875358	0.6283215	FALSE
soybean_price	-2.649470	0.3056741	FALSE

- Pelo resultado acima, é evidente que algumas séries não são estacionárias, dado o valor = “False” na coluna stationary . Nesse sentido, cabe aplicar a primeira diferença entre elas para assegurar a estacionariedade.

```

dataset_stationary <- dataset_final %>%
  group_by(series) %>%
  mutate(value = if_else(
    series %in% c("soybean_price", "fx", "commodity_fertilizers", "el_nino", 'soybean_global_price'),
    value - lag(value),
    value
  )) %>%
  ungroup()

first_dif_adf_test_list <- list()

for (i in series) {

  adf_data <- dataset_stationary %>%
    filter(series == i) %>%
    pull(value) %>%
    na.omit()

  if(length(adf_data) > 0){
    first_dif_adf_test_list[[i]] <- adf.test(adf_data)
  } else {
    first_dif_adf_test_list[[i]] <- NA
  }
}

```

```

}

adf_stationary_summary <- data.frame(
  series = names(first_dif_adf_test_list),
  test_stat = sapply(first_dif_adf_test_list, function(x) if(is.list(x)) x$statistic else NA),
  p_value = sapply(first_dif_adf_test_list, function(x) if(is.list(x)) x$p.value else NA),
  stationary = sapply(first_dif_adf_test_list, function(x) if(is.list(x)) x$p.value < 0.05 else NA)
)

adf_stationary_summary %>%
  mutate(series = gsub("\\.Dickey-Fuller$", "", as.character(series))) %>%
  kable(row.names = FALSE, caption = "Resultado Teste ADF - 2º Rodada")

```

Table 3: Resultado Teste ADF - 2º Rodada

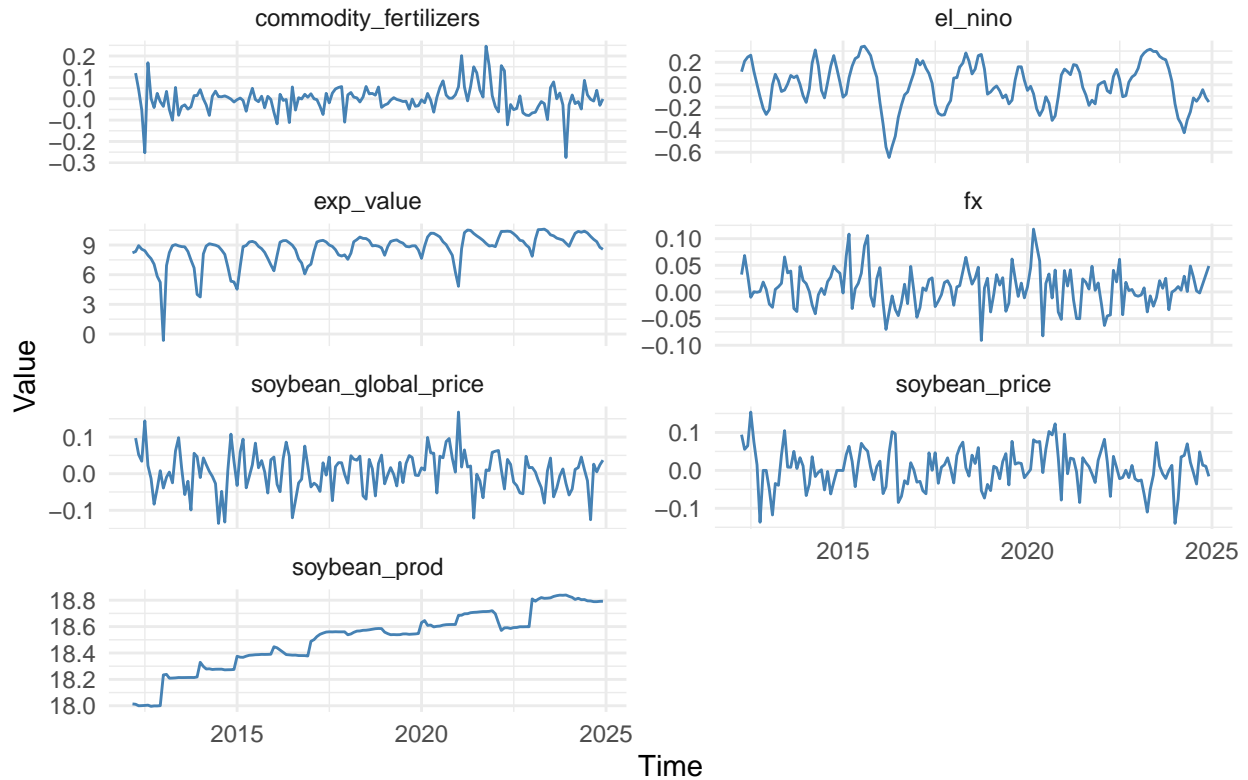
series	test_stat	p_value	stationary
fx	-3.953276	0.0133956	TRUE
commodity_fertilizers	-2.912142	0.1962387	FALSE
soybean_prod	-3.661281	0.0299999	TRUE
el_nino	-5.524341	0.0100000	TRUE
exp_value	-8.238062	0.0100000	TRUE
soybean_global_price	-4.804079	0.0100000	TRUE
soybean_price	-4.690300	0.0100000	TRUE

```

ggplot(dataset_stationary, aes(x = date, y = value)) +
  geom_line(color = "steelblue") +
  facet_wrap( ~ series, scales = "free_y", ncol = 2) +
  theme_minimal() +
  labs(title = "Time Series", x = "Time", y = "Value")

```

Time Series



- Como a série de “commodity_fertilizers” ainda não é estacionária, tomou-se a segunda diferença.

```
dataset_stationary_final <- dataset_stationary %>%
  group_by(series) %>%
  mutate(
    value = if_else(
      series == "commodity_fertilizers",
      value - lag(value, 2),
      value
    )
  ) %>%
  ungroup()

second_dif_adf_test_list <- list()

for (i in series) {

  adf_data <- dataset_stationary_final %>%
    filter(series == i) %>%
    pull(value) %>%
    na.omit()

  if(length(adf_data) > 0){
    second_dif_adf_test_list[[i]] <- adf.test(adf_data)
  } else {
    second_dif_adf_test_list[[i]] <- NA
  }
}
```



```

}

adf_stationary_final_summary <- data.frame(
  series = names(second_dif_adf_test_list),
  test_stat = sapply(second_dif_adf_test_list, function(x) if(is.list(x)) x$statistic else NA),
  p_value = sapply(second_dif_adf_test_list, function(x) if(is.list(x)) x$p.value else NA),
  stationary = sapply(second_dif_adf_test_list, function(x) if(is.list(x)) x$p.value < 0.05 else NA)
)

adf_stationary_final_summary %>%
  mutate(series = gsub("\\.Dickey-Fuller$", "", as.character(series))) %>%
  kable(row.names = FALSE,,caption = "Resultado Teste ADF - 3º Rodada")

```

Table 4: Resultado Teste ADF - 3º Rodada

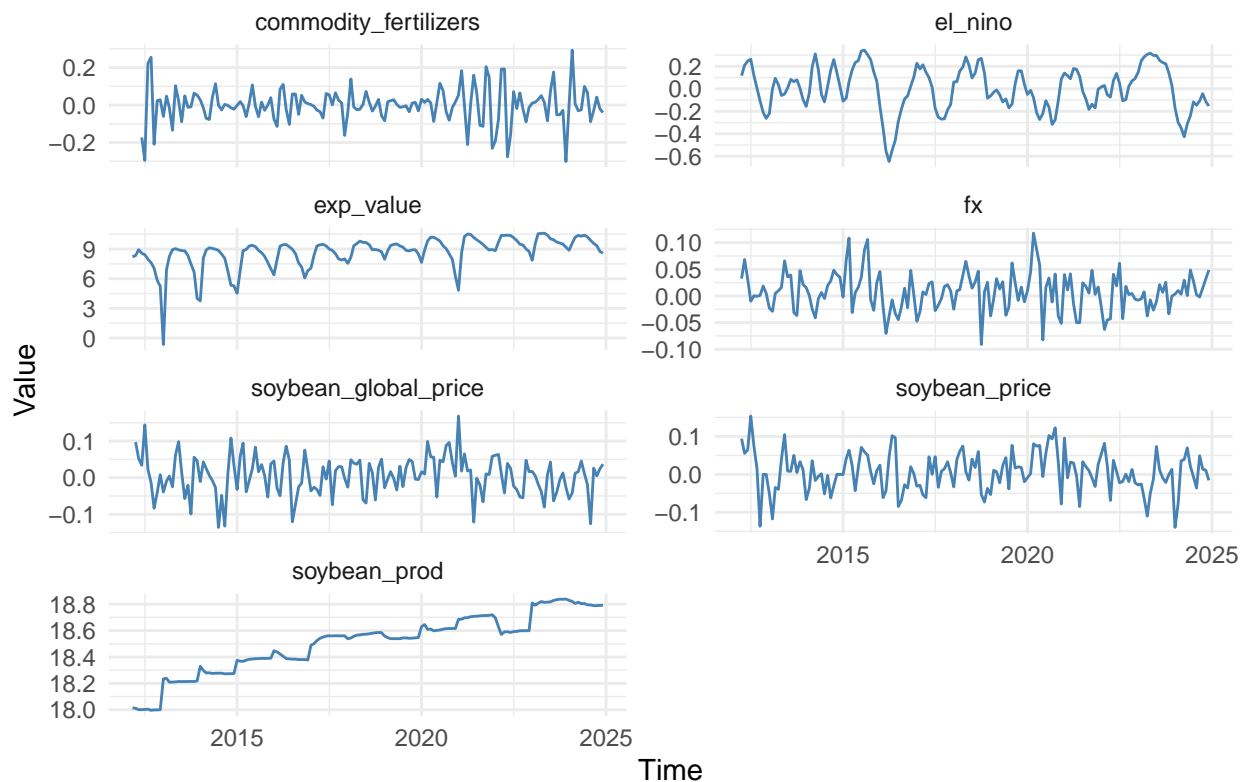
series	test_stat	p_value	stationary
fx	-3.953276	0.0133956	TRUE
commodity_fertilizers	-7.371674	0.0100000	TRUE
soybean_prod	-3.661281	0.0299999	TRUE
el_nino	-5.524341	0.0100000	TRUE
exp_value	-8.238062	0.0100000	TRUE
soybean_global_price	-4.804079	0.0100000	TRUE
soybean_price	-4.690300	0.0100000	TRUE

```

ggplot(dataset_stationary_final, aes(x = date, y = value)) +
  geom_line(color = "steelblue") +
  facet_wrap( ~ series, scales = "free_y", ncol = 2) +
  theme_minimal() +
  labs(title = "Time Series", x = "Time", y = "Value")

```

Time Series



Decomposição

- Pelo lado da decomposição, verificou-se que as séries apresentam uma tendência suave e um padrão de sazonalidade bem definido, enquanto a componente aleatório encontra-se relativamente controlada.

```
series_list <- unique(dataset_stationary_final$series)

stl_plots <- list()

for(s in series_list){

  df <- dataset_stationary_final %>%
    filter(series == s) %>%
    arrange(date)

  if(sum(!is.na(df$value)) < 24) next

  values_no_na <- df$value[!is.na(df$value)]
  dates_no_na <- df$date[!is.na(df$value)]

  ts_series <- ts(values_no_na,
    start = c(year(min(dates_no_na)), month(min(dates_no_na))),
    frequency = 12)

  stl_res <- stl(ts_series, s.window = "periodic", t.window = 12, robust = TRUE)
```

```

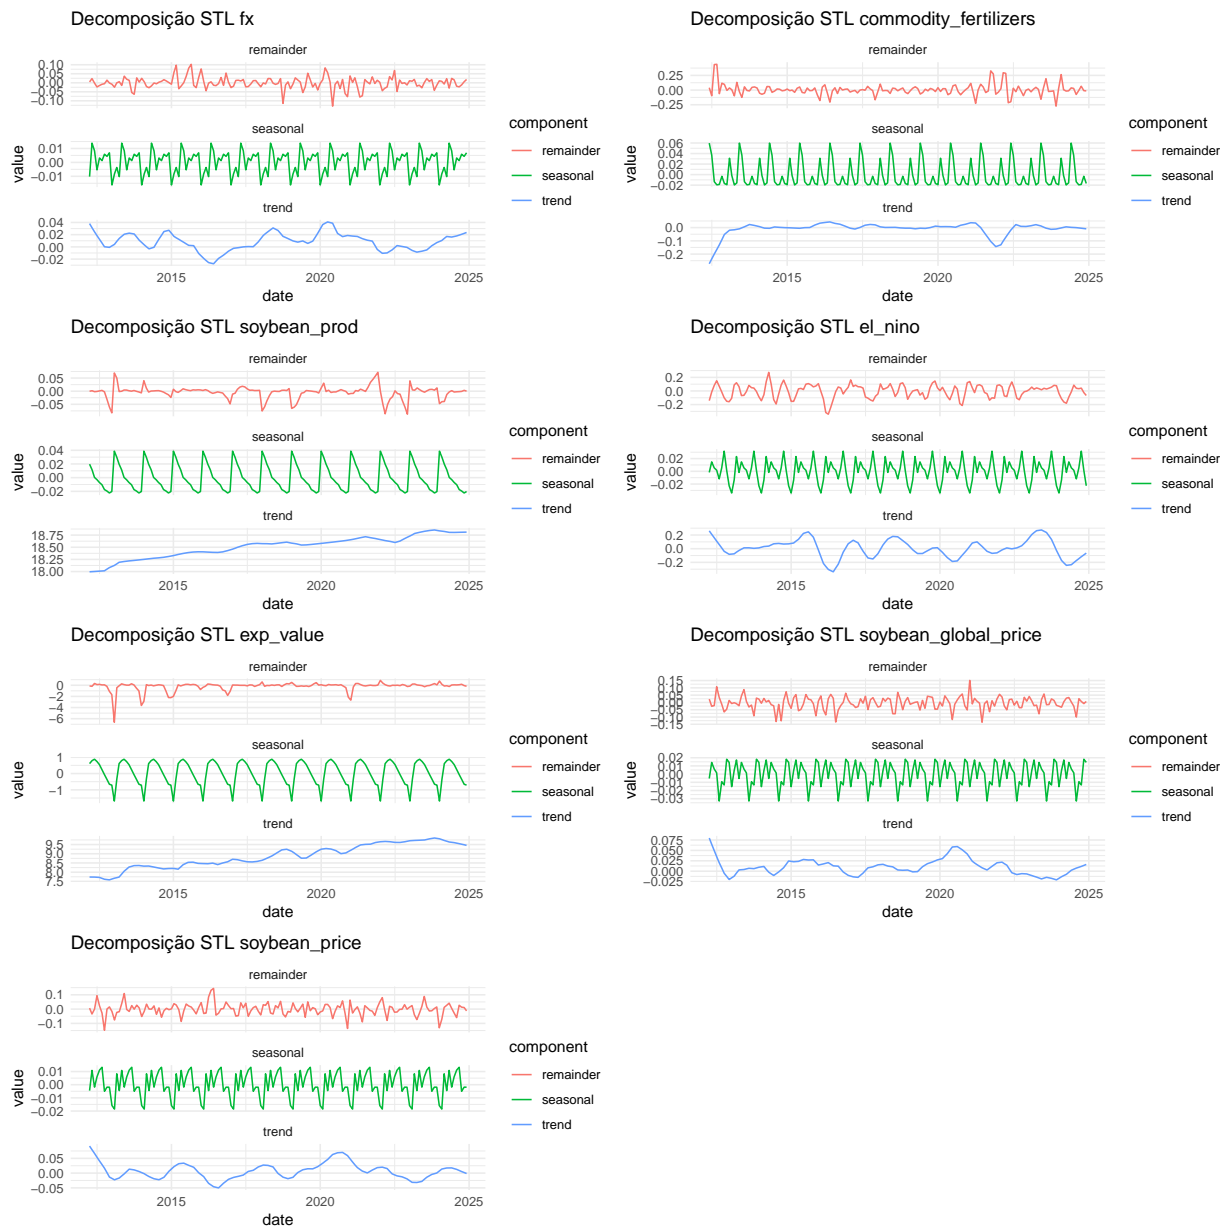
stl_df <- as.data.frame(stl_res$time.series)
stl_df$date <- dates_no_na
stl_df <- stl_df %>%
  pivot_longer(cols = -date, names_to = "component", values_to = "value")

p <- ggplot(stl_df, aes(x = date, y = value, color = component)) +
  geom_line() +
  facet_wrap(~component, scales = "free_y", ncol = 1) +
  labs(title = paste("Decomposição STL", s)) +
  theme_minimal()

stl_plots[[s]] <- p
}

wrap_plots(stl_plots, ncol = 2)

```

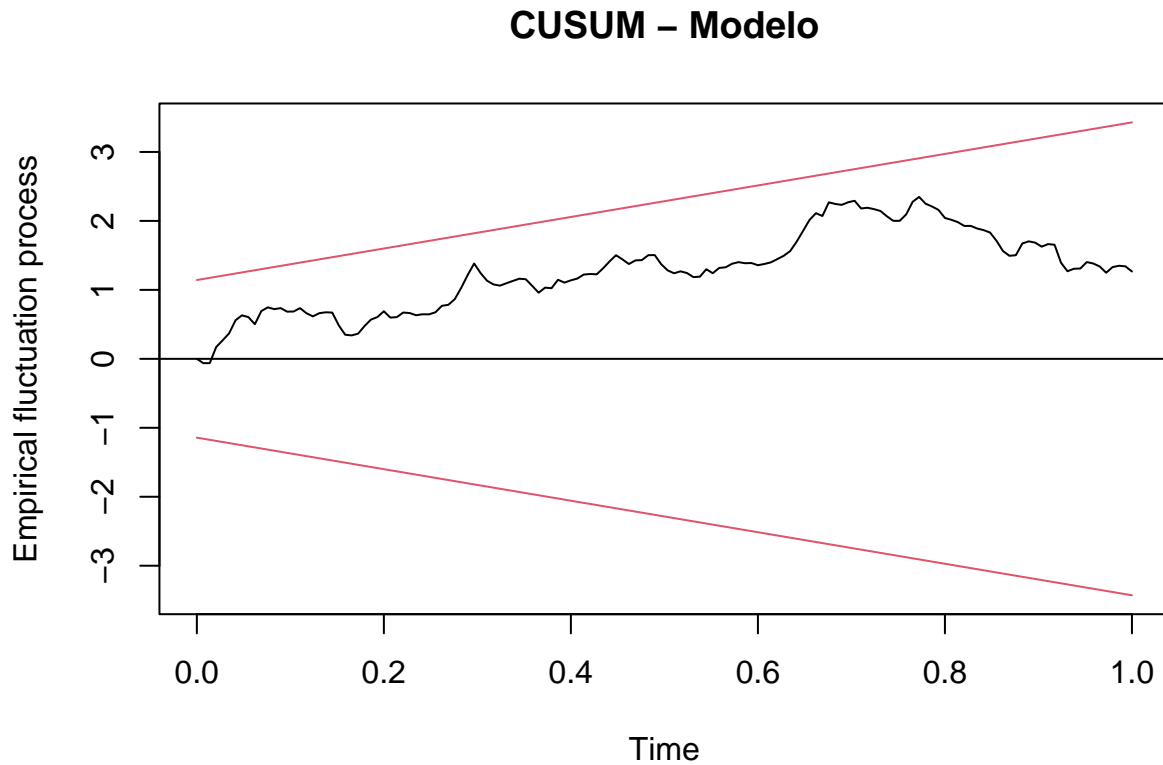


Quebra Estrutural

- No que se refere a quebras estruturais, aplicou-se o teste CUSUM, que avalia a estabilidade dos coeficientes ao longo do tempo, detectando mudanças abruptas ou tendências sistemáticas. Embora algumas séries possam apresentar quebras individuais, a análise agregada, considerando o comportamento do preço da soja, não indicou mudanças de regime significativas, sugerindo que o modelo mantém sua validade ao longo do período analisado.

```
df_model <- dataset_stationary_final %>%
  pivot_wider(
    names_from = series,
    values_from = value
  )
```

```
plot (efp(
  soybean_price ~ fx + commodity_fertilizers + exp_value + soybean_prod + el_nino,
  data = df_model,
  type = "Rec-CUSUM",
  h = 0.15), main = "CUSUM - Modelo", alpha = 0.01)
```



Modelo

- Para a estimação, considerou-se o preço da soja como variável dependente (Y) e os demais regressores do dataset como variáveis exógenas. Dessa forma, optou-se por um modelo ARIMA(1,0,0)(2,0,0), com AR(1) na componente não sazonal e AR(2) na componente sazonal.




```
soybean_ts <- ts(df_model$soybean_price, start = c(2012, 2), frequency = 12)

xreg <- df_model %>%
  dplyr::select(fx, commodity_fertilizers, soybean_prod, exp_value, el_nino, soybean_global_price) %>%
  as.matrix()

fit_arima <- auto.arima(soybean_ts, xreg = xreg)

checkresiduals(fit_arima)
```

Residuals from Regression with ARIMA(1,0,0)(2,0,0)[12] errors



```
##
##  Ljung-Box test
##
## data:  Residuals from Regression with ARIMA(1,0,0)(2,0,0)[12] errors
## Q* = 17.727, df = 21, p-value = 0.6662
##
## Model df: 3.   Total lags used: 24
summary(fit_arima)

## Series: soybean_ts
## Regression with ARIMA(1,0,0)(2,0,0)[12] errors
##
## Coefficients:
##      ar1      sar1      sar2  intercept      fx  commodity_fertilizers
## 0.2340 -0.0706  0.0893    0.6109  0.1661                -0.0385
## s.e.  0.0902  0.1007  0.1156    0.3267  0.0871                0.0289
##      soybean_prod  exp_value  el_nino  soybean_global_price
##      -0.0364      0.0074  -0.0281                0.6343
## s.e.      0.0182      0.0025  0.0167                0.0653
##
## sigma^2 = 0.001104:  log likelihood = 303.76
## AIC=-585.53  AICc=-583.63  BIC=-552.34
##
## Training set error measures:
##              ME      RMSE      MAE  MPE  MAPE      MASE      ACF1
## Training set -4.093899e-05 0.03233228 0.02453313 NaN  Inf  0.4133831 0.01639152
```

- A análise dos resíduos indica que eles se comportam como ruído branco, apresentando média próxima de zero e variância constante. O teste de Ljung-Box confirmou a ausência de autocorrelação significativa, com p-valor superior a 0,05. Além disso, o modelo apresentou um RMSE reduzido, sugerindo bom ajuste aos dados observados. Portanto, podemos considerar que o modelo está adequadamente especificado e ajusta-se bem à série histórica do preço da soja, mesmo que o correlograma dos resíduos (ACF) apresente um spike isolado fora do intervalo de confiança no lag 25, o qual pode ser interpretado como efeito aleatório despresível.

Análise Econômica

```
kable(
  round(coef(fit_arima), 2),
  caption = "Coeficientes do modelo ARIMA",
  col.names = c("Coeficiente", "Valor")
)
```

Table 5: Coeficientes do modelo ARIMA

Coeficiente	Valor
ar1	0.23
sar1	-0.07
sar2	0.09
intercept	0.61
fx	0.17
commodity_fertilizers	-0.04
soybean_prod	-0.04
exp_value	0.01
el_nino	-0.03
soybean_global_price	0.63

- A partir dos resultados do modelo, observa-se que as variáveis que mais influenciam o preço da soja no mercado doméstico são o câmbio e o preço internacional da soja. No caso do câmbio, considerando que grande parte da produção brasileira é destinada à exportação, maiores ganhos no mercado externo tendem a reduzir a oferta doméstica, pressionando os preços internos. Nesse sentido, um aumento de 1 R\$/USD no câmbio eleva o preço da soja em aproximadamente 0,16 R\$/60 kg. Quanto ao preço internacional, como o mercado doméstico acompanha os preços externos, há incentivos para ajustar o preço de venda internamente, de forma que um aumento de 1 USD/t no preço internacional eleva o preço doméstico em cerca de 0,63 R\$/60 kg.
- No que diz respeito às demais variáveis analisadas, o modelo não apresentou efeitos tão relevantes sobre o preço da soja. Entretanto, é plausível esperar que o El Niño e o preço dos fertilizantes exerçam um efeito defasado, pois tendem a impactar a produtividade da colheita de soja, o que posteriormente influencia os preços via oferta da commodity. Uma alternativa para validar essa hipótese seria incluir lags dessas variáveis no modelo e verificar seu efeito sobre o preço.
- Quanto à produção de soja, o modelo segue o racional de que, quanto maior a oferta, menor tende a ser o preço. Por fim, o aumento das exportações de soja tende a gerar uma pequena diminuição dos preços, uma vez que, quanto maior a oferta do item globalmente, o efeito sobre o preço internacional é negativo e, portanto, afetando o preço doméstico.

Elasticidade-preço do câmbio e do preço internacional da soja

Para entender a sensibilidade do preço doméstico da soja em relação às variáveis explicativas, podemos calcular a **elasticidade-preço**, definida como:

$$E_X = \frac{\Delta P/P}{\Delta X/X} \approx \beta \cdot \frac{\bar{X}}{\bar{P}}$$

onde:

- E_X = elasticidade-preço do **preço doméstico da soja** em relação à variável X
- ΔP = variação no **preço doméstico da soja (R\$/60 kg)**
- ΔX = variação na variável explicativa X
 - Para câmbio (R\$/USD)
 - Para preço internacional(R\$/60 kg)
- \bar{P} = preço médio da soja doméstica no período (R\$/60 kg)
- \bar{X} = valor médio da variável explicativa
- β = coeficiente estimado do modelo ARIMA para a variável X

```
# Média do preço doméstico (R$/60 kg)
P_bar <- mean(df_model$soybean_price, na.rm = TRUE)

# Média do câmbio (R$/USD)
fx_bar <- mean(df_model$fx, na.rm = TRUE)

# Média do preço internacional (R$/60 kg)
global_bar <- mean(df_model$soybean_global_price, na.rm = TRUE)

# Coeficientes
coef_model <- coef(fit_arima)

beta_fx <- coef_model["fx"]
beta_global <- coef_model["soybean_global_price"]

# Elasticidade em relação ao câmbio
E_fx <- beta_fx * fx_bar / P_bar

# Elasticidade em relação ao preço internacional
E_global <- beta_global * global_bar / P_bar

elasticidades <- tibble(
  Variável = c("Elasticidade Câmbio", "Elasticidade Preço Global"),
  Valor = c(E_fx, E_global)
)

kable(elasticidades, digits = 2, caption = "Elasticidades")
```


Table 6: Elasticidades

Variável	Valor
Elasticidade Câmbio	0.22
Elasticidade Preço Global	0.61

- A elasticidades das variáveis analisadas vem em linha com parâmetros gerados pelo modelo.
- **Taxa de câmbio:** Um aumento de 1% no câmbio (R\$/USD) eleva o preço doméstico da soja em 0,21%. Isso indica que o preço doméstico é moderadamente sensível às variações cambiais.
- **Preço internacional da soja:** Um aumento de 1% no preço global da soja eleva o preço doméstico em 0,61%. Isso mostra que o preço interno acompanha fortemente o mercado internacional, com sensibilidade relativamente alta. Ou seja, mudanças no preço internacional têm impacto direto e significativo sobre o preço doméstico.

Cenário What-If

```
# Horizonte de previsão
h <- 12

last_xreg <- tail(xreg, 1)

xreg_base <- matrix(rep(last_xreg, h), nrow = h, byrow = TRUE)

if(is.null(colnames(xreg))){
  colnames(xreg_base) <- c("fx", "commodity_fertilizers", "soybean_prod", "exp_value", "el_nino", "soybean_global_price")
} else {
  colnames(xreg_base) <- colnames(xreg)
}

# Cenário 1: câmbio desvalorizado 10%
xreg_fx_up <- xreg_base
xreg_fx_up[, "fx"] <- xreg_fx_up[, "fx"] * 1.10 # aumento de 10%

# Cenário 2: preço internacional da soja cai 15%
xreg_price_down <- xreg_base
xreg_price_down[, "soybean_global_price"] <- xreg_price_down[, "soybean_global_price"] * 0.85

# Previsões
fc_base <- forecast(fit_arma, xreg = xreg_base, h = h)
fc_fx_down <- forecast(fit_arma, xreg = xreg_fx_up, h = h)
fc_price_down <- forecast(fit_arma, xreg = xreg_price_down, h = h)


df_plot <- data.frame(
  date = time(fc_base$mean),
  Base = as.numeric(fc_base$mean),
  Fx_UP = as.numeric(fc_fx_down$mean),
  Price_Down = as.numeric(fc_price_down$mean)
```

```

) %>%
  pivot_longer(cols = -date, names_to = "Scenario", values_to = "Price")

ggplot(df_plot, aes(x = date, y = Price, color = Scenario)) +
  geom_line(size = 1) +
  geom_point(size = 1.5) +
  labs(
    title = "Simulação de Cenários - Preço da Soja (R$/ 60kg)",
    x = "Ano",
    y = "Preço da Soja",
    color = "Cenário"
  ) +
  theme_minimal() +
  theme(text = element_text(size = 12))

```



- Para a simulação do cenário What-If, considerou-se um horizonte de tempo de 12 meses, de modo que os efeitos dos choques ocorrem ao longo do ano de 2025.
- No que se refere ao choque aplicado ao câmbio, uma desvalorização do real frente ao dólar tende a elevar o preço doméstico da saca de 60 kg de soja em comparação ao cenário básico, que pressupõe todas as demais variáveis constantes. A dinâmica observada nesse cenário está consistente com o modelo, evidenciando o efeito positivo do câmbio sobre o preço doméstico da soja. Nesse sentido, uma variação positiva do câmbio pode gerar incentivos para maior produção e exportação, uma vez que a rentabilidade da venda externa tende a aumentar. Por outro lado, devido à menor oferta doméstica, observa-se uma redução da disponibilidade de soja no mercado interno, o que, consequentemente, tende

a pressionar o preço para cima.

- Quanto ao choque aplicado ao preço internacional da soja, as evidências indicam uma queda no preço doméstico frente ao cenário básico. A relação entre as variáveis é positiva, sendo o preço internacional um dos principais vetores que impacta o preço interno da commodity. Portanto, uma redução de preços pode incentivar a diminuição da produção, uma vez que a rentabilidade tende a cair, ao passo que a demanda pelo produto no mercado interno pode se manter estável ou até aumentar, devido ao menor preço. Esse ajuste no equilíbrio entre oferta e demanda tende a conter parcialmente a queda de preços domésticos, mas evidencia a forte sensibilidade do mercado interno às variações internacionais.